组会论文汇报 · Vision-Language Navigation

Towards Realistic UAV Vision-Language Navigation: Platform, Benchmark, and Methodology

面向真实无人机视觉 - 语言导航：平台、基准与方法（ TravelUAV / OpenUAV ）

论文： Xiangyu Wang*, Donglin Yang*, Ziqin Wang*, Hohin Kwan, Jinyu Chen, Wenjun Wu, Hongsheng Li, Yue Liao † , Si Liu †
单位： 北京航空航天大学人工智能研究院 · CUHK MMLab · CPII
出处： arXiv:2410.07087 (2024) · 项目主页 prince687028.github.io/OpenUAV

汇报人： ____ 日期： 2026 年 10 月

汇报提纲

01	研究背景与动机	地面 VLN 设定难以直接迁移到无人机
02	OpenUAV 仿真平台	逼真环境 × 真实飞控 × 算法支持
03	数据集与基准	12,149 条 6-DoF 轨迹 + UAV-Need-Help
04	UAV 导航大模型	MLLM 分层轨迹生成 + 回溯采样 DAgger
05	实验与结果	全面超越基线，与人类差距依然显著
06	结论与展望	贡献总结与未来方向

直接沿用地面 VLN 设定，无法胜任真实无人机导航

Background • 两类智能体的运动学与任务复杂度存在本质差异

运动动力学失配

- 地面智能体：水平面移动，离散动作（前进 / 转向）即可规划
- 无人机：三维空域 6 自由度机动——俯仰、翻滚、偏航同时发生
- 连续轨迹难以分解为离散动作 → 固定动作集产生「非真实」导航

任务复杂度失配

- 无人机多在开阔户外执行长距离、长航时任务
- 视点高速变化、遮挡频发，仅凭目标描述难以精确搜索
- 需要环境信息与在线引导的持续支持

结论：需要为无人机 VLN 重建平台、数据与方法的整个技术栈

图源 / 数据： Wang et al., arXiv:2410.07087, Fig.1 与 Sec.1

现有 UAV VLN 数据集均未覆盖真实 6-DoF 飞行动态

Related Work · 与代表性 VLN 数据集对比（Table 1）

数据集	DoF	运动学	轨迹数	词表	轨迹长 (m)	指令长	动作数
R2R (2018)	—	✗	7,189	3.1K	10	29	5
TouchDown (2019)	2	✗	9,326	5K	310	90	35
AVDN (2022)	3	✗	6,269	3.3K	144	89	7
AerialVLN (2023)	4	✗	8,446	4.5K	661	83	204
CityNav (2024)	4	✗	32,637	6.6K	545	26	—
本文 TravelUAV	**6**	**✓**	**12,149**	**10.8K**	**255**	**104**	**264**

首个具备真实飞行动力学（6-DoF 运动学 ✓）的无人机 VLN 数据集

数据源： Wang et al., arXiv:2410.07087, Table 1

OpenUAV 平台：逼真环境、真实飞控与算法支持三位一体

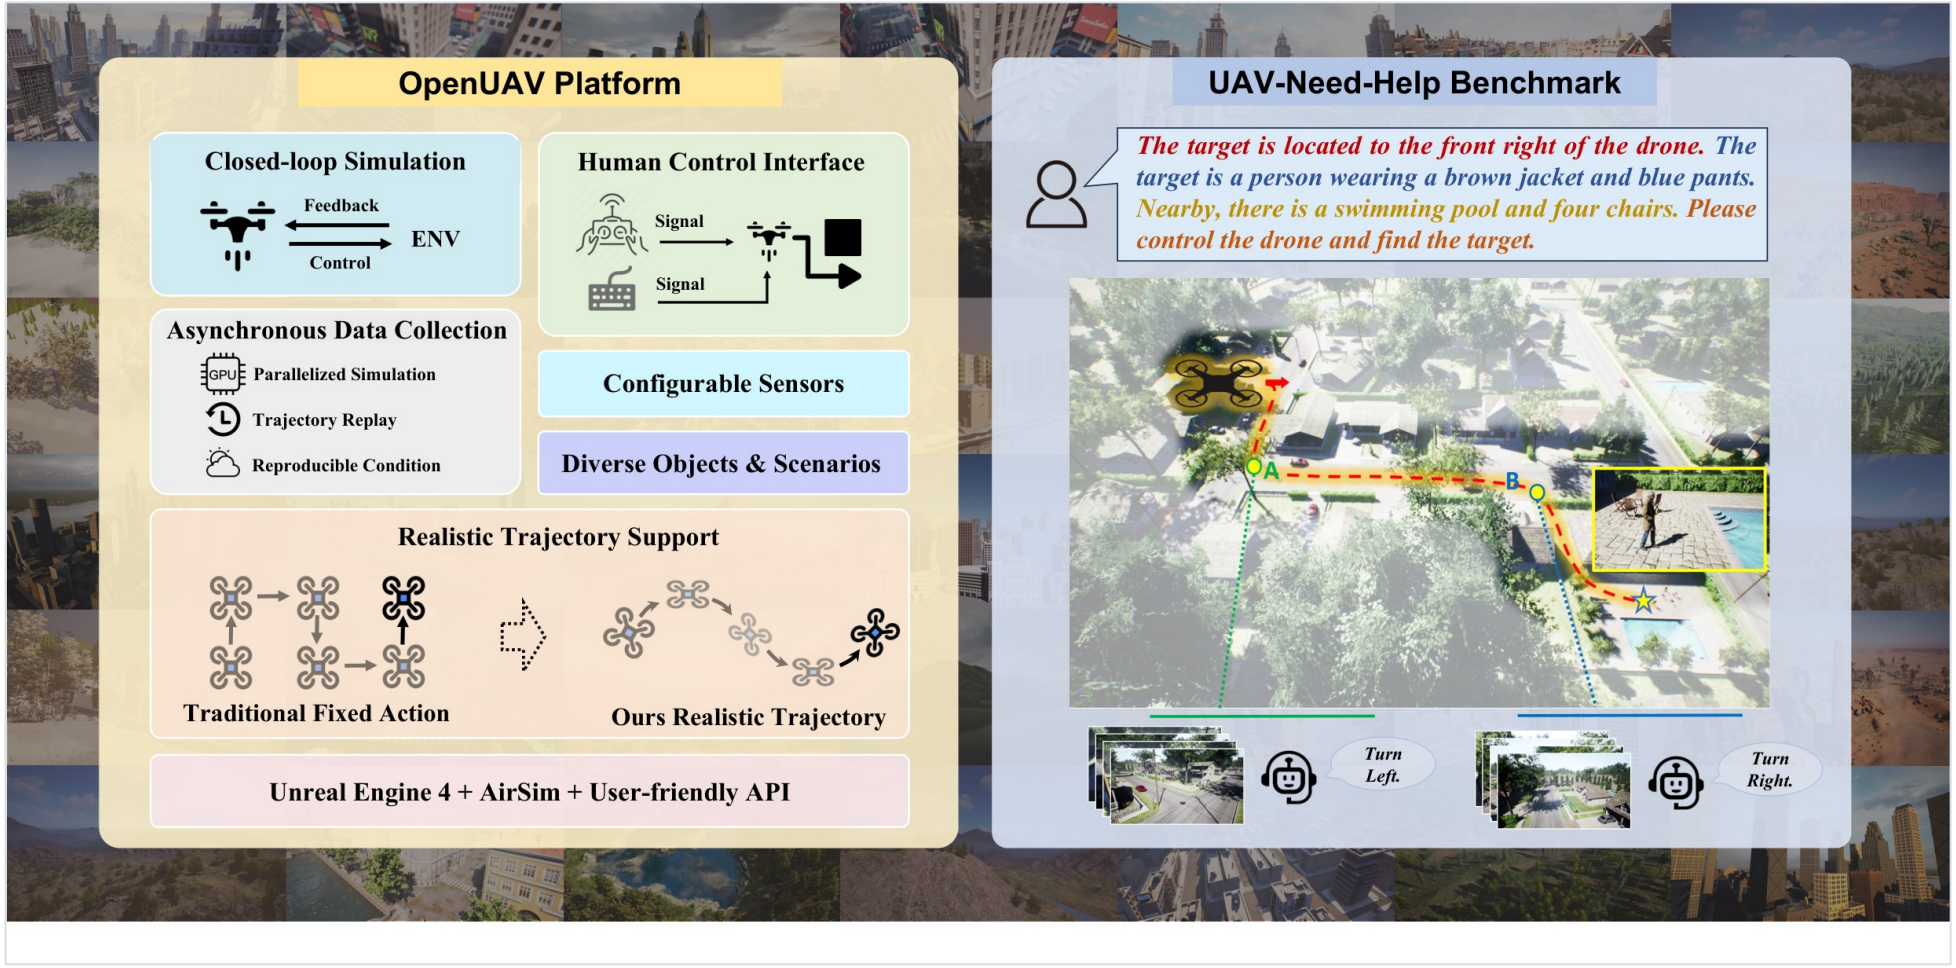


图 1 ｜平台与基准总览：左为 OpenUAV 平台（闭环仿真、并行化、可复现条件、传感器配置、轨迹回放），右为 UAV-Need-Help 助导式目标搜索任务。

图源： arXiv:2410.07087, Fig.1

OpenUAV 平台： UE4 + AirSim ， 22 场景全流程开放

逼真环境

- UE4 高保真渲染， 22 类城市场景
- 89 类可放置物体资产，运行时 API 自动摆放
- 动态环境：植被摆动、光照变化

真实飞控

- AirSim 物理仿真， 6-DoF 位姿 $P=\{x,y,z,\theta,\phi,\psi\}$
- 遥控器（ PX4 ） / 手动 / 位置模式三种人控接口
- RGB+ 深度 ×5 视角、 360° LiDAR 、 IMU 、 GPS

算法支持

- 闭环仿真：模型输出→飞控→环境反馈
- DAgger 数据聚合 + 回溯策略内置
- 8×A100 并行 16× 加速， 160–1600 fps

全平台开源：环境、飞控、采集、训练、评测一体化，支撑连续轨迹 VLN 研究全流程

内容源： arXiv:2410.07087, Sec.3

12,149 条 6-DoF 真实轨迹： GPT-4 生成描述 + 人工驾机采集

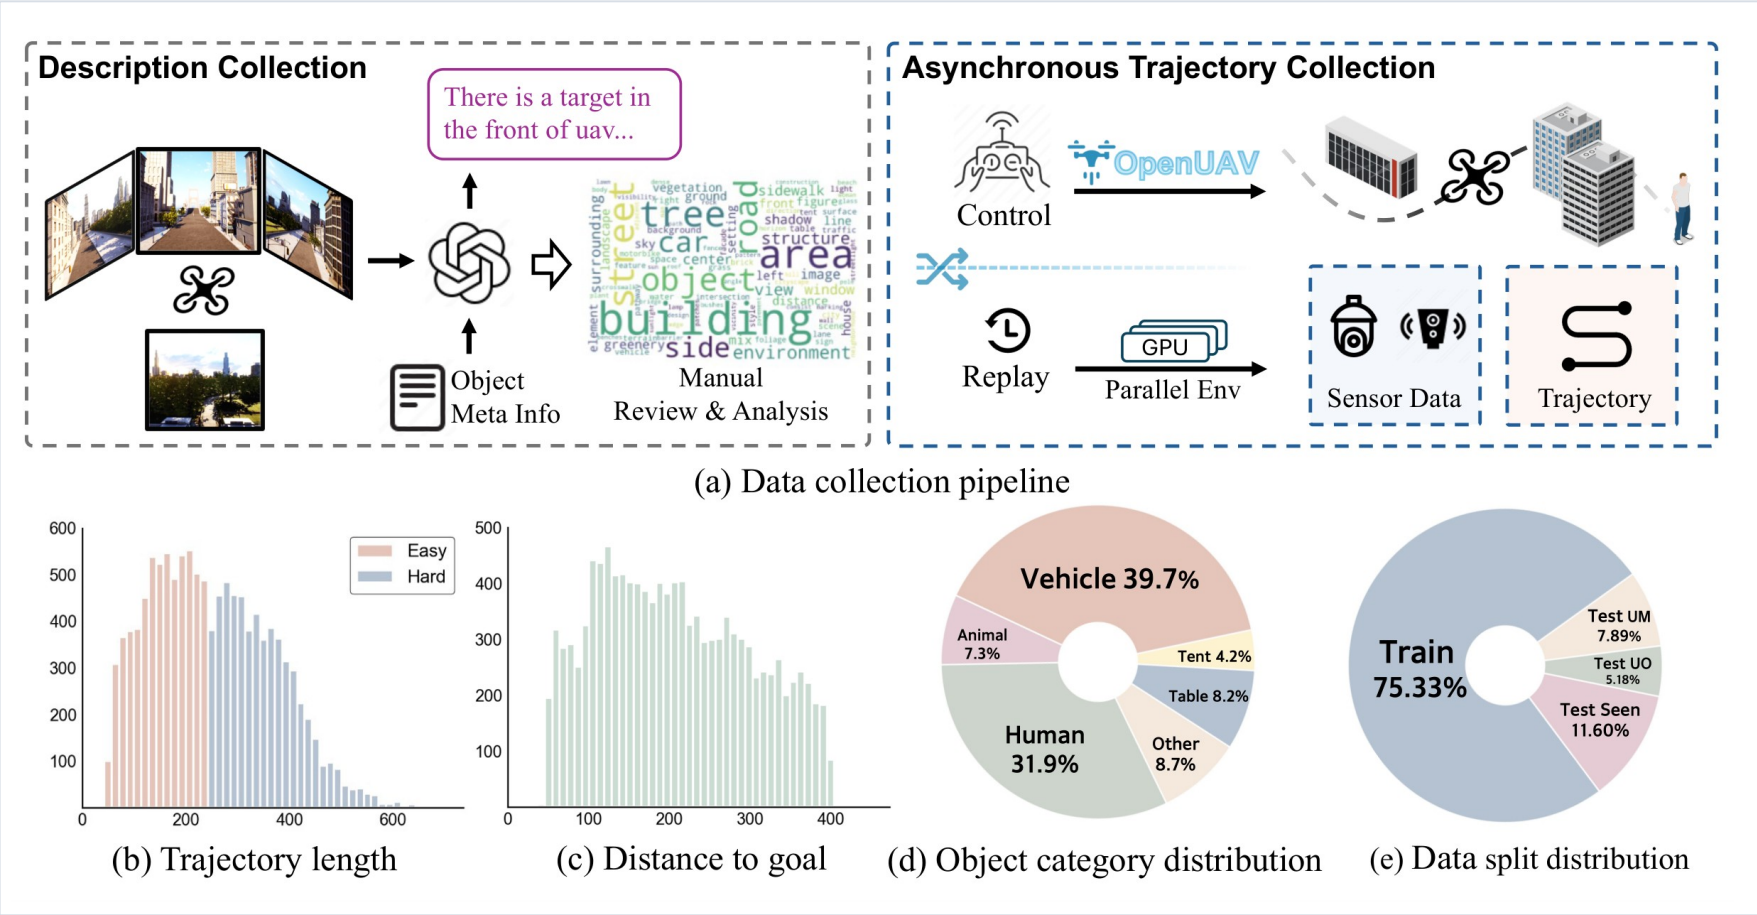


图 2 ｜数据构建与统计：五视角拍摄→ GPT-4 生成目标描述→人工复核；飞手实时驾机、状态等间隔记录、传感器异步补采；右侧为轨迹长度 / 目标距离 / 物体类别 / 数据划分分布。

图源： arXiv:2410.07087, Fig.2 ； 划分： Train 9,152 / Test Seen 1,410 / Unseen Map 958 / Unseen Object 629

UAV-Need-Help： 三级助导机制适配真实搜救场景

Benchmark • 助手依据场景提供不同粒度的在线引导

L1 全程引导	持续计算 UAV 与最优路径最近点，高频给出巡航 / 转向 / 降落指令	贴近真实地面站协作
L2 纠偏引导	仅当深度图判定碰撞风险或偏离路径时介入，低频纠正	模拟远程监督者
L3 避障引导	仅在危险临近障碍时发出避障指令	最大 autonomy ，最难设定

任务形式化：每回合输入 { 目标描述 I, 状态 S, 五视角 RGB R 与深度 D, 助手指令 I'} → 模型输出 6-DoF 轨迹序列；降落点距目标 **20 米内**记为成功。

内容源： arXiv:2410.07087, Sec.5

UAV 导航大模型：以可学习查询驱动分层轨迹生成

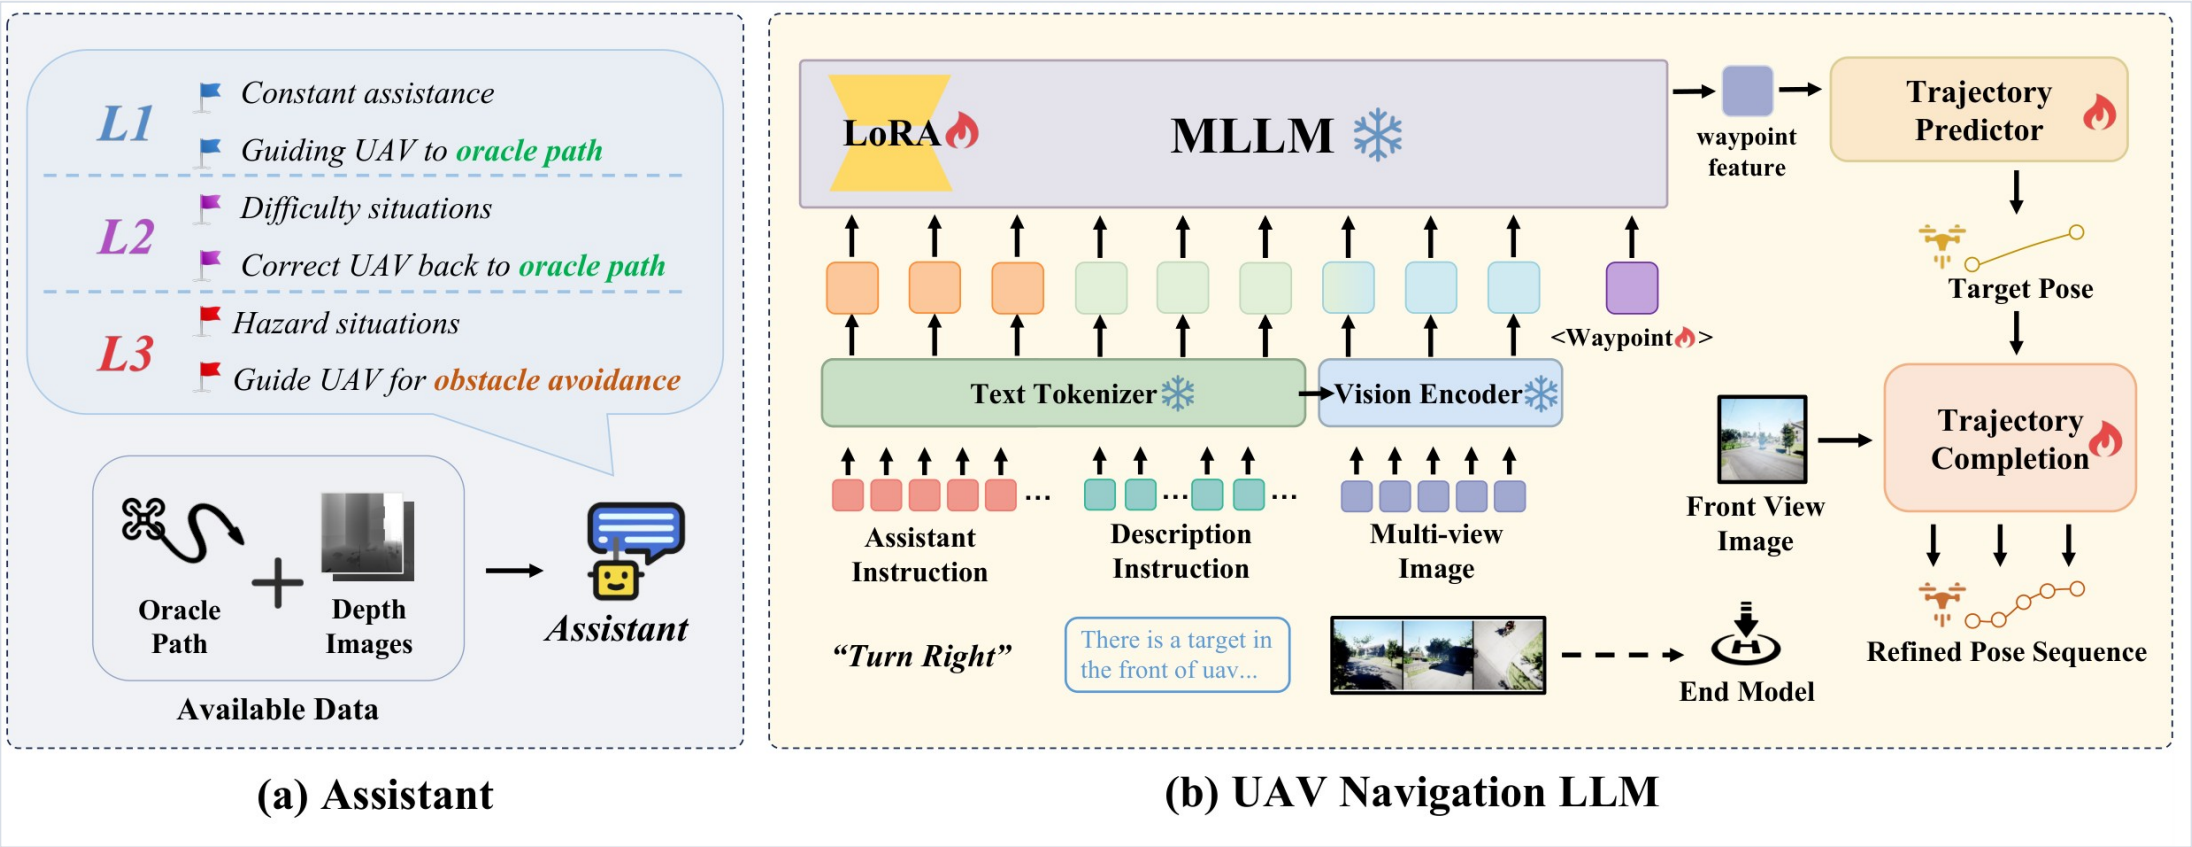


图 3 | 左：三级助手机制；右：导航 LLM—— 指令与多视角图像编码进 MLLM （Vicuna-7B）， waypoint 查询 token 提取特征预测远距目标位姿，再由前视细化解码器生成精细轨迹。

图源： arXiv:2410.07087, Fig.3

分层解码：先定远距目标位姿，再生成精细轨迹

01

多模态 tokenization

- EVA-CLIP + Q-former： 每视角 1 全局 + 16 局部 token
- 拼接 <T_img, T_task, T_instr> 输入 Vicuna-7B

02

高层轨迹解码

- 可学习 waypoint token T_wp 经 LLM 提取轨迹特征
- MLP 解码下一目标位姿 P_target（远距离规划）

03

细粒度路径解码

- 前视 token + 目标位姿特征对齐 → MLP 输出位姿序列
- Grounding DINO 检出目标即触发降落

训练增强：回溯采样 DAgger—— 模型输出致碰撞时回退两帧并改用教师轨迹，从失败中采集避障样本

内容源： arXiv:2410.07087, Sec.6

全部指标超越基线： SR 较 CMA 平均提升 5 个百分点

Experiments · Test Seen， L1 助手（Table 2， Full 口径）

方法	NE (m) ↓	SR (%) ↑	OSR (%) ↑	SPL (%) ↑
Random	222.20	0.14	0.21	0.07
Fixed Action	188.61	2.27	8.16	1.40
CMA (LSTM)	135.73	8.37	18.72	7.90
Ours	106.28	16.10	44.26	14.30
Ours + 回溯 DA	**98.66**	**17.45**	**48.87**	**15.76**
Human	**14.15**	**94.51**	**94.51**	**77.84**

+109%

SR 相对 CMA 提升（8.37→17.45）

3.4×

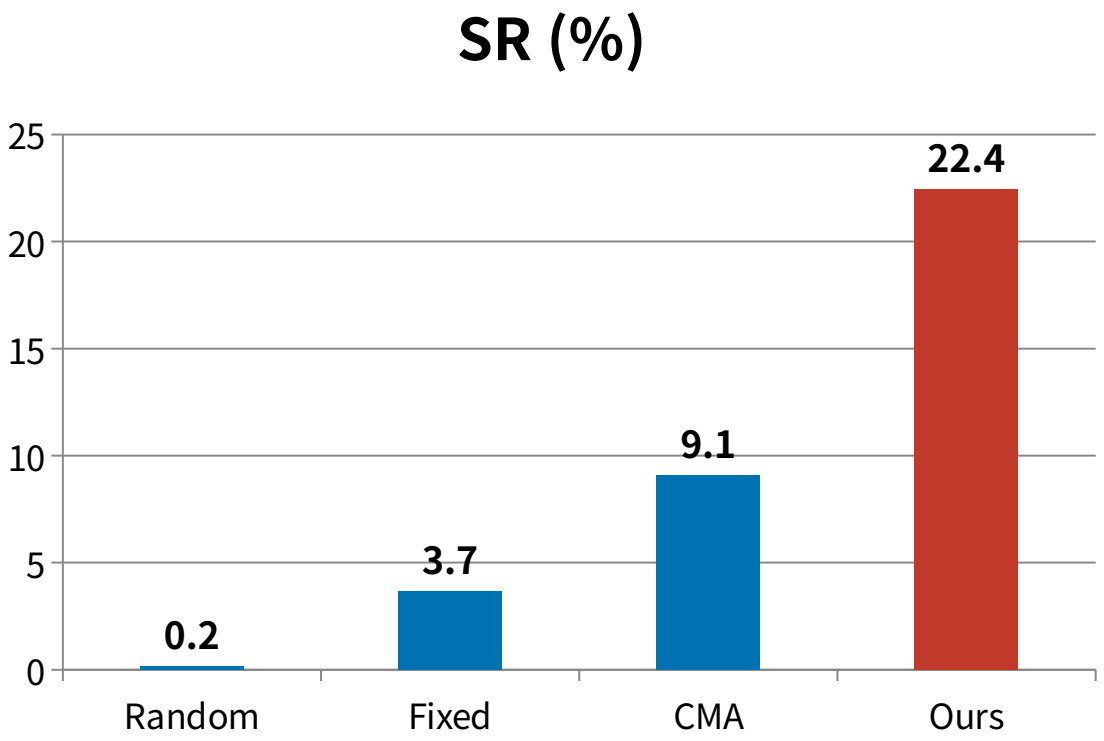
OSR 提升（18.72→48.87）：接近半数任务可途经最优路径

差距仍大

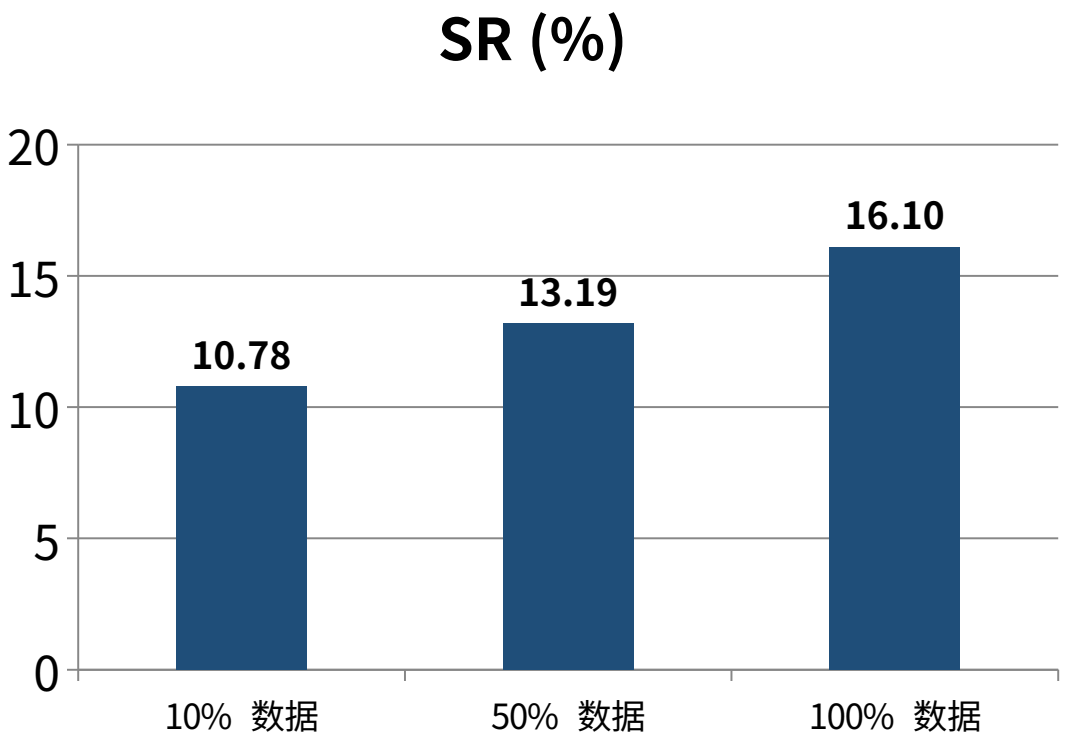
人类 SR 94.51 vs 模型 17.45—— 任务远未解决

数据源： arXiv:2410.07087, Table 2； NE= 终点距目标平均距离

未见物体上泛化最优： SR 22.4% ，数据越多性能越强



Test Unseen Object （L1 助手） SR 对比



训练数据量消融（Test Seen, L1, SR% ）

Unseen Map 上 SR 仅 4.18%：未见城市场景仍是核心挑战

数据源： arXiv:2410.07087, Table 3 / Table 4

成功案例遵循指令完成搜索；失败多源于复杂场景碰撞



图 4 ｜前两行为成功案例：无人机依指令定位车辆与奶牛，第 3–5 帧可见转向机动改变视点；第三行为失败案例：森林场景中与树木碰撞。

图源： arXiv:2410.07087, Fig.4

结论：平台、基准、方法三件套重塑真实无人机 VLN

01	平台	OpenUAV：首个面向连续轨迹无人机 VLN 的全开源仿真平台（UE4+AirSim， 22 场景）
02	数据与基准	12,149 条 6-DoF 轨迹数据集 + UAV-Need-Help 三级助导基准，均开源
03	方法	UAV 导航大模型：分层轨迹生成 + 回溯采样 DAgger， SR 较 CMA 平均 +5pt

不足与展望：模型与人类操作员仍有 77pt SR 差距；未见场景泛化（Unseen Map SR 4.18%）与真实无人机部署是下一步核心方向。

谢谢大家，敬请批评指正 • Q&A